

Лабораторная работа №3

Данные для работы - <https://disk.yandex.ru/d/LFXoBfhm1ZfluQ>

Цель: Освоить работу с документо-ориентированной СУБД MongoDB на примере иерархического каталога товаров, научиться проектировать структуры данных с денормализацией и работать с агрегационным фреймворком

Подготовительный этап

К docker-compose предыдущей лабораторной были добавлены mongo и mongo express. Второе добавлено из-за невозможности установить MongoDB Compass на локальную машину с FedoraOS.

CONTAINER ID	IMAGE	COMMAND	CREATED	STATUS NAMES	PORTS
6c236ac19bd4	mongo-express	"/sbin/tini -- /dock..."	47 minutes ago	Up 47 minutes mongo-express	0.0.0.0:8085->8081/tcp, [::]:8085->8081/tcp
1dc0b946a644	mongo:7.0	"docker-entrypoint.s..."	48 minutes ago	Up 48 minutes mongodb-dev	0.0.0.0:27017->27017/tcp, [::]:27017->27017/tcp
52f62c4462b9	clickhouse/clickhouse-server:24.1	"/entrypoint.sh"	20 hours ago	Up 20 hours	9009/tcp, 0.0.0.0:8124->8123/tcp, [::]:8124->8123/tcp, 0.0.0.0:9001->9000/tcp, [::]:9001->9000/tcp, 0.0.0.0:9364->9363/tcp, [::]:9364->9363/tcp
a7f519d7bf37	grafana/grafana:latest	"/run.sh"	43 hours ago	Up 43 hours ch-grafana	0.0.0.0:3001->3000/tcp, [::]:3001->3000/tcp
ed91a03904b5	prom/prometheus:latest	"/bin/prometheus --c..."	43 hours ago	Up 43 hours ch-prometheus	0.0.0.0:9091->9090/tcp, [::]:9091->9090/tcp
9ed3420e2e76	grafana/grafana:latest	"/run.sh"	2 days ago	Up 2 days grafana	0.0.0.0:3005->3000/tcp, [::]:3005->3000/tcp
4a57344e5374	postgres:16-alpine	"docker-entrypoint.s..."	2 days ago	Up 2 days (healthy) postgres-dev	0.0.0.0:5433->5432/tcp, [::]:5433->5432/tcp
35923107b201	prom/prometheus:latest	"/bin/prometheus --c..."	2 days ago	Up 2 days prometheus	0.0.0.0:9090->9090/tcp, [::]:9090->9090/tcp
cf0257ba8edf	prometheuscommunity/postgres-exporter:latest	"/bin/postgres_expor..."	2 days ago	Up 2 days postgres-exporter	0.0.0.0:9187->9187/tcp, [::]:9187->9187/tcp
1d773a778167	metabase/metabase:latest	"/app/run_metabase.sh"	2 weeks ago	Up 2 weeks metabase	0.0.0.0:3000->3000/tcp, [::]:3000->3000/tcp
cb71003f7f89	caddy:2-alpine	"caddy run --config ..."	3 months ago	Up 3 months vk-parser-caddy-1	0.0.0.0:80->80/tcp, [::]:80->80/tcp, 0.0.0.0:443->443/tcp, [::]:443->443/tcp, 0.0.0.0:443->443/udp, [::]:443->443/udp, 2019/tcp
b442bd0ba1a4	vk-parser-app	"dotnet VParserSamo..."	3 months ago	Up 3 months vk-parser-app	0.0.0.0:8080->8080/tcp, [::]:8080->8080/tcp
07407c19f77b	postgres	"docker-entrypoint.s..."	3 months ago	Up 3 months vkparser_postgres_db	0.0.0.0:5432->5432/tcp, [::]:5432->5432/tcp

Рис 1. - список запущенных контейнеров

ЧАСТЬ 1: ПРОЕКТИРОВАНИЕ И ЗАГРУЗКА ДАННЫХ

Задание 1.1: Анализ исходных данных и проектирование схемы

Цель: Понять структуру исходных данных и спроектировать оптимальную схему для MongoDB

Исходные данные: parquet файл, где каждая строка содержит информацию об одном товаре с привязкой к категории через поле Category_FullPathName (формат: "Уровень1\Уровень2\Уровень3...")

Задачи:

1. Определить, сколько уникальных категорий в датасете
2. Определить максимальную глубину вложенности категорий
3. Выявить категории с наибольшим количеством товаров

4. Понять, есть ли товары с одинаковыми Offer_ID у разных партнеров
5. Определить, сколько уникальных типов товаров (Offer_Type) представлено в данных

Результат

1. Уникальных категорий: 5261
2. Максимальная глубина: 8
3. Максимальное количество товаров в одной категории - 300, всего таких категорий - 4246. Топ 10 категорий:
 - a. Строительство и ремонт\Инструменты для ремонта и строительства\Пневмоинструменты\Прочие пневмоинструменты
 - b. Автотовары\Запчасти для легковых автомобилей\Система очистки стекол и фар\Комплекующие стеклоочистителя
 - c. Хобби и творчество\Рисование\Краски для рисования\Краски акварельные
 - d. Хобби и творчество\Рисование\Краски для рисования\Краски акриловые
 - e. Хобби и творчество\Рисование\Краски для рисования\Краски масляные
 - f. Хобби и творчество\Рисование\Краски для рисования\Краски темпераные
 - g. Хобби и творчество\Рисование\Холсты, артборды и картон грунтованный
 - h. Автотовары\Запчасти для легковых автомобилей\Система очистки стекол и фар\Резинки щеток стеклоочистителя
 - i. Строительство и ремонт\Силовая техника и оборудование\Комплекующие для ЧПУ
 - j. Хобби и творчество\Рисование\Краски для рисования\Гуашь
4. Нет, все Offer_ID разные, а партнер один, значит не повторяются
5. Уникальных Offer_Type: 12379

Данные представлены в формате parquet со следующими столбцами:

- Partner_Name - имя маркетплейса. В этих данных везде равно _ozon - партнер один
- Category_ID - уникальный идентификатор категории (уникальный для каждого уникального Category_FullPathName) - всего 5261 уникальных
- Category_FullPathName - плоская иерархия категорий - 5261 уникальных - сходится с числом уникальных Category_ID, можно верить, что для двух одинаковых
- Category_FullPathName совпадут Category_ID. Максимальная глубина вложенности - 8.
- Offer_ID - идентификатор предложения, 1355049 уникальных при 1355049 записей всего - РК
- Offer_Name - название предложения, 983437 уникальных
- Offer_Type - тип предложения, 12379 уникальных

Обоснование выбора создания двух коллекций (categories и products) вместо одной: Разделение данных на две коллекции обусловлено различной природой и жизненным циклом сущностей «категория» и «товар». Категории представляют собой иерархическую справочную структуру с относительно редкими изменениями, но частыми иерархическими запросами (поиск подкатегорий, навигация по дереву, аналитика по уровням). Товары, напротив, являются высоко объёмными и часто читаемыми сущностями, для которых критично быстрое получение всей информации без дополнительных join-операций. Хранение категорий и товаров в одной коллекции привело бы к многократному дублированию иерархии категорий, усложнению обновлений и увеличению размера документов. Выделение отдельной коллекции categories с использованием паттерна Materialized Path позволяет эффективно выполнять иерархические запросы и аналитику по структуре каталога. Коллекция products, в свою очередь, использует денормализацию и встраивание информации о категории, что оптимизирует сценарии чтения и соответствует рекомендуемым практикам MongoDB для высоконагруженных read-oriented систем.

Преимущества денормализации: 1. Скорость чтения (всё в одном документе); 2. Упрощение логики хлебных крошек (breadcrumbs) на фронтенде; 3. Атомарность данных о товаре.

Задание 1.2: Создание коллекции категорий (categories)

Цель: Преобразовать плоскую таблицу с иерархическими путями в структурированные документы MongoDB с применением паттерна "Materialized Path"

Требования к структуре документа:

- `_id`: строка вида "partner_categoryid" (например, "_ozon_10000")
- `partner`: название партнера (например, "_ozon")
- `category_id`: идентификатор категории (строка)
- `name`: название категории — последний элемент иерархии (например, "Прочие пневмоинструменты")
- `path`: полный путь категории с разделителем "/" (например, "Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты/Прочие пневмоинструменты")
- `path_array`: массив строк с элементами пути для иерархических запросов (["Строительство и ремонт", "Инструменты для ремонта и строительства", "Пневмоинструменты", "Прочие пневмоинструменты"])
- `level`: числовое значение уровня вложенности (1, 2, 3, 4...)
- `parent_path`: путь к родительской категории (строка или null для категорий 1-го уровня)
- `metadata`: вложенный объект:

- total_products: количество товаров в категории (целое число)
- last_updated: дата и время обновления (ISODate)

Алгоритм формирования:

- Пройти по всем строкам pq
- Для каждой уникальной комбинации Partner_Name + Category_ID создать один документ категории
- Подсчитать количество товаров (total_products) по всем строкам с этой категорией

Результат

Была создана коллекция категорий

_id	partner	category_id	name	path	path_array	level	parent_path	metadata
_ozon_10000	_ozon	10000	Прочие пневмоинструменты	Строительство и ремонт/Инструменты для ремонта и ...	Строительство и ремонт/Инструменты для ремонта и строительства,Пневмоинструменты,Прочие пневмоинструменты	4	Строительство и ремонт/Инструменты для ремонта и ...	{ "total_products": 300, "last_updated": ISODate("2026-01-08T18:05:10.692Z") }
_ozon_10012	_ozon	10012	Аксессуары и оснастка для пневмоинструментов	Строительство и ремонт/Инструменты для ремонта и ...	Строительство и ремонт/Инструменты для ремонта и строительства,Пневмоинструменты,Аксессуары и оснастка для пневмоинструментов	4	Строительство и ремонт/Инструменты для ремонта и ...	{ "total_products": 300, "last_updated": ISODate("2026-01-08T18:05:10.692Z") }
_ozon_10031	_ozon	10031	Шланги воздушные для компрессора	Строительство и ремонт/Инструменты для ремонта и ...	Строительство и ремонт/Инструменты для ремонта и строительства,Пневмоинструменты,Шланги воздушные для компрессора	4	Строительство и ремонт/Инструменты для ремонта и ...	{ "total_products": 300, "last_updated": ISODate("2026-01-08T18:05:10.692Z") }

Рис 2. - Коллекция категорий

Editing Document: _ozon_10000

```

1 {
2   _id: '_ozon_10000',
3   partner: '_ozon',
4   category_id: '10000',
5   name: 'Прочие пневмоинструменты',
6   path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты/Прочие пневмоинструменты',
7   path_array: [
8     'Строительство и ремонт',
9     'Инструменты для ремонта и строительства',
10    'Пневмоинструменты',
11    'Прочие пневмоинструменты'
12  ],
13   level: 4,
14   parent_path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты',
15   metadata: {
16     total_products: 300,
17     last_updated: ISODate('2026-01-08T18:05:10.692Z')
18   }
19 }

```

Рис 3. - Пример документа №1



Рис 4. - Пример документа №2

```
Общее количество категорий: 5261
Уровень 1: 2 категорий
Уровень 2: 85 категорий
Уровень 3: 1488 категорий
Уровень 4: 3224 категорий
Уровень 5: 315 категорий
Уровень 6: 131 категорий
Уровень 7: 12 категорий
Уровень 8: 4 категорий
```

Рис 5. - Статистика по категориям

Задание 1.3: Создание коллекции товаров (products)

Цель: Создать коллекцию товаров с денормализованной информацией о категориях (паттерн "Embedded Documents")

Требования к структуре документа:

- _id: строка вида "partner_offerid" (например, "_ozon_1606856085")
- partner: название партнера (строка)
- offer_id: идентификатор товара (строка)
- name: название товара (строка)
- type: тип товара (строка, например, "Степлер строительный")
- category: вложенный объект с информацией о категории:
- id: идентификатор категории (строка)
- name: название категории (строка)
- full_path: полный путь категории (строка с "/")
- breadcrumbs: массив объектов для навигации, каждый элемент содержит:

- level: уровень в иерархии (1, 2, 3...)
- name: название категории на этом уровне
- created_at: дата создания записи (ISODate)
- updated_at: дата последнего обновления (ISODate)

Важно: В отличие от коллекции categories, здесь каждая строка pq превращается в один документ товара. Информация о категории дублируется (денормализация) для быстрого доступа без JOIN операций.

Результат

Mongo Express Database: ecom_catalog Collection: products

Delete all 1355049 documents retrieved

1 2 3 4 5 > >>

_id	partner	offer_id	name	type	category
  _ozon_1606856085	_ozon	1606856085	Пневматический скобозабивной каркасный пистолет М...	Степлер строительный	<pre>{ "id": "10000", "name": "Прочие пневмоинструменты", "full_path": "Строительство и ремонт/Инструменты для ремонта и стро...", "breadcrumbs": @ [4 items] }</pre>
  _ozon_2651828947	_ozon	2651828947	Степлер строительный	Степлер строительный	<pre>{ "id": "10000", "name": "Прочие пневмоинструменты", "full_path": "Строительство и ремонт/Инструменты для ремонта и стро...", "breadcrumbs": @ [4 items] }</pre>
  _ozon_2039307712	_ozon	2039307712	Пистолет пневматический	Пистолет гвоздезабивной	<pre>{ "id": "10000" }</pre>

Рис 6. - Коллекция продуктов

```
Mongo Express Database: ecom_catalog -> Collection: products -> Document _ozon_1606856085

1 {
2   _id: '_ozon_1606856085',
3   partner: '_ozon',
4   offer_id: '1606856085',
5   name: 'Пневматический скобозабивной каркасный пистолет MEITE MT-N851-H',
6   type: 'Степлер строительный',
7   category: {
8     id: '10000',
9     name: 'Прочие пневмоинструменты',
10    full_path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты/Прочие пневмоинструменты',
11    breadcrumbs: [
12      {
13        level: 1,
14        name: 'Строительство и ремонт'
15      },
16      {
17        level: 2,
18        name: 'Инструменты для ремонта и строительства'
19      },
20      {
21        level: 3,
22        name: 'Пневмоинструменты'
23      },
24      {
25        level: 4,
26        name: 'Прочие пневмоинструменты'
27      }
28    ]
29  },
30  created_at: ISODate('2026-01-08T18:06:07.681Z'),
31  updated_at: ISODate('2026-01-08T18:06:07.681Z')
32 }
```

Рис 7. - Пример документа в коллекции продуктов

```
Общее количество товаров: 1355049

Топ-5 типов товаров (Offer_Type):
- Лекарственное средство безрецептурное: 10167 шт.
- Печатная книга: 9657 шт.
- Лекарственное средство рецептурное: 8528 шт.
- Электронная книга: 3382 шт.
- Сумка: 3106 шт.

Распределение по партнерам:
- _ozon: 1355049 товаров
```

Рис 8. - Статистика коллекции продуктов

Задание 1.4: Создание индексов для оптимизации запросов

Цель: Создать индексы для ускорения типовых запросов к иерархическим данным

Требования для коллекции categories:

1. Текстовый индекс на поле path — для полнотекстового поиска по категориям
2. Индекс на поле path_array — для запросов "найти все подкатегории"
3. Составной индекс на поля partner и level — для выборки категорий определенного уровня у партнера
4. Индекс на поле metadata.total_products — для сортировки по популярности категорий

Требования для коллекции products:

1. Составной индекс на поля partner и category.id — для выборки товаров категории

2. Индекс на поле category.breadcrumbs.name — для поиска по любому уровню категории
3. Составной индекс на поля type и partner — для аналитики по типам товаров
4. Индекс на поле offer_id — для быстрого поиска товара по идентификатору

Результат

```
ecom_catalog;> db.categories.getIndexes();
[
  { v: 2, key: { _id: 1 }, name: '_id_' },
  {
    v: 2,
    key: { _fts: 'text', _ftsx: 1 },
    name: 'path_text',
    weights: { path: 1 },
    default_language: 'english',
    language_override: 'language',
    textIndexVersion: 3
  },
  { v: 2, key: { path_array: 1 }, name: 'path_array_1' },
  { v: 2, key: { partner: 1, level: 1 }, name: 'partner_1_level_1' },
  {
    v: 2,
    key: { 'metadata.total_products': -1 },
    name: 'metadata.total_products_-1'
  }
]
```

Рис 9. - Индексы для категорий


```
ecom_catalog;> db.products.getIndexes();
[
  { v: 2, key: { _id: 1 }, name: '_id_' },
  {
    v: 2,
    key: { partner: 1, 'category.id': 1 },
    name: 'partner_1_category.id_1'
  },
  {
    v: 2,
    key: { 'category.breadcrumbs.name': 1 },
    name: 'category.breadcrumbs.name_1'
  },
  { v: 2, key: { type: 1, partner: 1 }, name: 'type_1_partner_1' },
  { v: 2, key: { offer_id: 1 }, name: 'offer_id_1' }
]
```

Рис 10. - Индексы для продуктов

```
Коллекция: categories
Размер данных: 3.17 MB
Размер индексов: 1.11 MB
Процент индексов: 34.96%

Коллекция: products
Размер данных: 987.93 MB
Размер индексов: 107.48 MB
Процент индексов: 10.88%
```

Рис 11. - Статистика размеров данных и индексов

Высокий процент объема индексов в коллекции categories объясняется использованием «тяжелых» типов: текстового индекса для поиска по путям и Multikey-индекса для массива `path_array`. В коллекции products показатель в 11% считается идеальным балансом, обеспечивающим полное покрытие запросов при экономном расходе ресурсов. Совокупный объем индексов (~108 МБ) гарантированно помещается в оперативную память (RAM), что исключает медленные обращения к диску при поиске. Денормализация данных в товарах оправдала себя: мы получили быстрый доступ к хлебным крошкам ценой допустимого увеличения объема хранилища. Все критические операции — от поиска подкатегорий до фильтрации по типам — теперь выполняются через **IXSCAN** вместо полного сканирования коллекции. Данная конфигурация полностью соответствует рекомендациям MongoDB по обеспечению высокой производительности Resident Set. Спроектированная архитектура готова к промышленной эксплуатации и эффективной обработке сложных агрегационных запросов.

ЧАСТЬ 2: БАЗОВЫЕ ЗАПРОСЫ К ИЕРАРХИЧЕСКИМ ДАННЫМ

Задание 2.1: Навигация по иерархии категорий

Выполнить следующие запросы к коллекции `categories` и зафиксировать результаты:

Запрос 1: Найти все категории первого уровня (корневые) для партнера `"_ozon"`

- Условие: `level = 1` и `partner = "_ozon"`

Запрос 2: Найти все подкатегории (любого уровня), которые входят в "Строительство и ремонт"

- Использовать поле `path_array` и оператор поиска в массиве

Запрос 3: Топ-10 самых "населенных" категорий по количеству товаров

- Сортировка по `metadata.total_products` (по убыванию)

Результат

The screenshot shows a database query interface. At the top, there is a query input field containing `{ level: 1, partner: "_ozon" }` and a projection field. A blue button labeled "Find" is on the right. Below the query fields is a red bar with the text "Delete all 2 documents retrieved". The main part of the interface displays a table of search results. The table has columns: `_id`, `partner`, `category_id`, `name`, `path`, `path_array`, `level`, `parent_path`, and `metadata`. Two rows are visible, each with a blue link icon and a red delete icon. The first row corresponds to category `_ozon_13100` (Music and Video) and the second to `_ozon_16500` (Books). The `metadata` column for each row shows a JSON object with `total_products` and `last_updated` values.

_id	partner	category_id	name	path	path_array	level	parent_path	metadata
_ozon_13100	_ozon	13100	Музыка и видео	Музыка и видео	Музыка и видео	1		<pre>{ "total_products": 300, "last_updated": "2026-01-08T18:05:18.415Z" }</pre>
_ozon_16500	_ozon	16500	Книги	Книги	Книги	1		<pre>{ "total_products": 300, "last_updated": "2026-01-08T18:05:27.097Z" }</pre>

Рис 12. - найденные категории первого уровня

Simple

Advanced

{ path_array: "Строительство и ремонт" }

Projection

☐ Aggregate query

Find

Delete all 540 documents retrieved

1 2 3 4 5 > >>

_id	partner	category_id	name	path	path_array	level	parent_path	metadata
_ozon_10000	_ozon	10000	Прочие пневмоинструменты	Строительство и ремонт/Инструменты для ремонта и ...	Строительство и ремонт,Инструменты для ремонта и строительства,Пневмоинструменты,Прочие пневмоинструменты	4	Строительство и ремонт/Инструменты для ремонта и ...	{ "total" "last_u" }
_ozon_10012	_ozon	10012	Аксессуары и	Строительство	Строительство и ремонт,Инструменты для	4	Строительство	

Рис 13. - Найденные подкатегории которые входят в "Строительство и ремонт"

```
ecom_catalog> db.categories.find().sort({ "metadata.total_products": -1 }).limit(10);
[
  {
    _id: '_ozon_10000',
    partner: '_ozon',
    category_id: '10000',
    name: 'Прочие пневмоинструменты',
    path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты/Прочие пневмоинструменты',
    path_array: [
      'Строительство и ремонт',
      'Инструменты для ремонта и строительства',
      'Пневмоинструменты',
      'Прочие пневмоинструменты'
    ],
    level: 4,
    parent_path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты',
    metadata: {
      total_products: 300,
      last_updated: ISODate('2026-01-08T18:05:10.692Z')
    }
  },
  {
    _id: '_ozon_10012',
    partner: '_ozon',
    category_id: '10012',
    name: 'Аксессуары и оснастка для пневмоинструментов',
    path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты/Аксессуары и оснастка для пневмоинструментов',
    path_array: [
      'Строительство и ремонт',
      'Инструменты для ремонта и строительства',
      'Пневмоинструменты',
      'Аксессуары и оснастка для пневмоинструментов'
    ],
    level: 4,
    parent_path: 'Строительство и ремонт/Инструменты для ремонта и строительства/Пневмоинструменты',
    metadata: {

```

Рис 14. - Топ-10 самых "населенных" категорий по количеству товаров

Задание 2.2: Работа с товарами и вложенными документами

Выполнить следующие запросы к коллекции products:

Запрос 1: Найти все товары типа "Степлер строительный", у которых в иерархии категорий (breadcrumbs) есть уровень "Пневмоинструменты"

- Условие: type = "Степлер строительный" И category.breadcrumbs.name содержит "Пневмоинструменты"

Запрос 2: Найти товары, которые находятся на 4-м уровне иерархии категорий

- Использовать размер массива breadcrumbs или проверку существования 4-го элемента

Запрос 3: Найти количество товаров в каждой категории 1-го уровня

- Группировка: взять первый элемент из category.breadcrumbs (level = 1)

- Подсчитать количество товаров в каждой группе

- Использовать базовую агрегацию с \$group

Результат

The screenshot shows the Mongo Express web interface. At the top, it indicates the database is 'ecom_catalog' and the collection is 'products'. A search query is entered in the left panel:

```
{
  "type": "Степлер строительный",
  "category.breadcrumbs.name": "Пневмоинструменты"
}
```

. The right panel shows an empty 'Projection' field and a checked 'Aggregate query' option. A red banner below the query area says 'Delete all 47 documents retrieved'. Below this is a pagination bar with numbers 1 through 5 and navigation arrows. The main results area displays a table with columns: _id, partner, offer_id, name, type, and category. Two results are visible. The first result has an _id of '_ozon_1606856085', partner '_ozon', offer_id '1606856085', name 'Пневматический скобозабивной каркасный пистолет М...', type 'Степлер строительный', and a category object containing 'id', 'name', 'full_path', and 'breadcrumbs' (with 4 items). The second result has an _id of '_ozon_2651828947', partner '_ozon', offer_id '2651828947', name 'Степлер строительный', type 'Степлер строительный', and a category object with 'id'.

_id	partner	offer_id	name	type	category
_ozon_1606856085	_ozon	1606856085	Пневматический скобозабивной каркасный пистолет М...	Степлер строительный	{ "id": "10000", "name": "Прочие пневмоинструменты", "full_path": "Строительство и ремонт/Инструменты для ремонта и строи...", "breadcrumbs": [4 items] }
_ozon_2651828947	_ozon	2651828947	Степлер строительный	Степлер строительный	{ "id": "10000",

Рис 15. - все товары типа "Степлер строительный", у которых в иерархии категорий (breadcrumbs) есть уровень "Пневмоинструменты"

Mongo Express Database: ecom_catalog Collection: products

Simple Advanced

{ "category.breadcrumbs.3": { "\$exists": true } }

Projection

Aggregate query Find

Delete all 916561 documents retrieved

1 2 3 4 5 > >>

_id	partner	offer_id	name	type	category
 	_ozon	1606856085	Пневматический скобозабивной каркасный пистолет М...	Стеллер строительный	<pre>{ "id": "10000", "name": "Прочие пневмоинструменты", "full_path": "Строительство и ремонт/Инструменты для ремонта и ст...", "breadcrumbs": @ [4 items] }</pre>

Рис 16. - товары, которые находятся на 4-м уровне иерархии категорий

Mongo Express Database: ecom_catalog Collection: products

Simple Advanced

[{ "\$project": { "root_name": { "\$arrayElemAt": ["\$category.breadcrumbs.name", 0] } }, { "\$group": { "_id": "\$root_name", "total": { "\$sum": 1 } } }, { "\$sort": { "total": -1 } }]

Projection

Aggregate query Find

Delete all 29 documents retrieved

1 2 3 > >>

_id	total
  Строительство и ремонт	158566
  Дом и сад	144499
  Автотовары	119483
  Ozon fresh	78327

Рис 17. - количество товаров в каждой категории 1-го уровня

ЧАСТЬ 3: АГРЕГАЦИОННЫЙ ФРЕЙМВОРК

Задание 3.1: Аналитика по категориям

Агрегация 1: Топ-10 категорий по количеству товаров с детальной статистикой

Создать агрегационный pipeline:

- Группировка по category.id
- Вычислить: общее количество товаров (count), название категории (взять из первого документа), полный путь категории
- Отсортировать по количеству товаров (убывание)
- Ограничить результат первыми 10 записям

Результат




Рис 18. - Топ-10 категорий по количеству товаров с детальной статистикой

Как упоминалось ранее самое большое кол-во товаров в категории - 300, и таких категорий 4246. Исходя из статистики выполнения запроса (Рис. 19) общее время выполнения составило 1818 (курсор) + 2041 (группировка) + 2041 (сортировка) мс, т.е 5900 мс

```

    },
    nReturned: Long('1355049'),
    executionTimeMillisEstimate: Long('1818')
  },
  {
    '$group': {
      _id: '$category.id',
      count: { '$sum': { '$const': 1 } },
      name: { '$first': '$category.name' },
      full_path: { '$first': '$category.full_path' }
    },
    maxAccumulatorMemoryUsageBytes: {
      count: Long('505056'),
      name: Long('673070'),
      full_path: Long('1185918')
    },
    totalOutputDataSizeBytes: Long('2727053'),
    usedDisk: false,
    spills: Long('0'),
    spilledDataStorageSize: Long('0'),
    numBytesSpilledEstimate: Long('0'),
    spilledRecords: Long('0'),
    nReturned: Long('5261'),
    executionTimeMillisEstimate: Long('2041')
  },
  {
    '$sort': { sortKey: { count: -1 }, limit: Long('10') },
    totalDataSizeSortedBytesEstimate: Long('5328'),
    usedDisk: false,
    spills: Long('0'),
    spilledDataStorageSize: Long('0'),
    nReturned: Long('10'),
    executionTimeMillisEstimate: Long('2041')
  }
}

```

Рис 19. - Статистика выполнения запроса


Задание 3.2: Иерархическая статистика по уровням

Создать агрегационный pipeline:

- Развернуть массив category.breadcrumbs с помощью \$unwind
- Группировка по двум полям: уровню (breadcrumbs.level) и названию категории (breadcrumbs.name)
- Подсчитать количество товаров на каждом уровне для каждой категории

- Отсортировать: сначала по уровню (возрастание), затем по количеству товаров (убывание)
- Ограничить первыми 30 записям

Результат



```

[
  { "$unwind": "$category.breadcrumbs" },
  { "$group": {
    "_id": {
      "level": "$category.breadcrumbs.level",
      "name": "$category.breadcrumbs.name"
    },
    "product_count": { "$sum": 1 }
  } },
  { "$sort": { "_id.level": 1, "product_count": -1 } },
  { "$limit": 30 },
  { "$project": { "level": "$_id.level", "name": "$_id.name", "product_count": 1,
    "_id": 0 } }
]

```

product_count	level	name
158566	1	Строительство и ремонт
144499	1	Дом и сад
119483	1	Автотовары

Рис. 20 - Агрегационный pipeline

На 1 уровне больше всего товаров. Топ-3: Строительство и ремонт, Дом и сад, Автотовары.

На 2 уровне - Запчасти для легковых автомобилей, Инструменты для ремонта и строительства, Дача и сад.

На 3 уровне - Бытовая техника, Аксессуары и материалы для рукоделия, Садовый инструмент

Задание 3.3: Анализ структуры категорий

Цель: Понять глубину и разветвленность дерева категорий

Выполнить следующие агрегации на коллекции categories:

Агрегация А: Распределение категорий по уровням и партнерам

- Группировка по partner и level
- Подсчитать количество категорий и сумму товаров для каждой комбинации
- Отсортировать по партнеру и уровню

Агрегация Б: Категории-"листья" (конечные категории без подкатегорий)

- Найти категории, для которых не существует других категорий с parent_path равным их path
- Использовать \$lookup для самосоединения коллекции categories

- Отфильтровать те, у которых массив дочерних категорий пустой
- Показать топ-10 листьев по количеству товаров

Результат

Текст первой агрегации - [

```
{ "$group": {
  "_id": { "partner": "$partner", "level": "$level" },
  "count_categories": { "$sum": 1 },
  "sum_products": { "$sum": "$metadata.total_products" }
}},
{ "$sort": { "_id.partner": 1, "_id.level": 1 } },
{ "$project": {
  "partner": "$_id.partner",
  "level": "$_id.level",
  "count_categories": 1,
  "sum_products": 1,
  "_id": 0
}}
]
```

Mongo Express Database: ecom_catalog > Collection: categories

Delete all 8 documents retrieved

categories_count	total_products	partner	level
2	600	_ozon	1
85	21753	_ozon	2
1488	416135	_ozon	3
3224	859577	_ozon	4
315	39074	_ozon	5
131	15762	_ozon	6
12	1605	_ozon	7
4	543	_ozon	8

Рис 21. - Распределение категорий по уровням и партнерам

Текст второй агрегации - [

```
{ "$lookup": {
  "from": "categories",
  "localField": "path",
  "foreignField": "parent_path",
  "as": "children"
}},
{ "$match": { "children": { "$size": 0 } } },
```

```

{ "$sort": { "metadata.total_products": -1 } },
{ "$limit": 10 },
{ "$project": {
  "name": 1,
  "path": 1,
  "total_products": "$metadata.total_products",
  "_id": 0
}}
]

```

name	path	total_products
Пистолеты для герметиков	Строительство и ремонт/Инструменты для ремонта и ...	300
Валики и малярные ванночки	Строительство и ремонт/Инструменты для ремонта и ...	300
Степлеры и антистеплеры строительные	Строительство и ремонт/Инструменты для ремонта и ...	300
Малярные кисти	Строительство и ремонт/Инструменты для ремонта и ...	300
Пистолеты для пены	Строительство и ремонт/Инструменты для ремонта и ...	300
Шпатели	Строительство и ремонт/Инструменты для ремонта и ...	300
Аксессуары и оснастка для пневмоинструментов	Строительство и ремонт/Инструменты для ремонта и ...	300
Прочие пневмоинструменты	Строительство и ремонт/Инструменты для ремонта и ...	300
Шланги воздушные для компрессора	Строительство и ремонт/Инструменты для ремонта и ...	300
Малярные ленты	Строительство и ремонт/Лакокрасочные материалы/Ма...	300

Рис. 22 - атегории-"листья" (конечные категории без подкатегорий)